Sujet de stage M2 / École Ingénieur

INRAE - UMR TETIS, Montpellier, France

Titre

Explicabilité des modèles de langues appliquée à l'information géographique

Keywords

Traitement Automatique du Langage (TAL), Grand Modèle de Langage (LLM), Explicabilité, Information géographique

Description courte

Ce stage vise à adapter les méthodes d'interprétabilité mécaniste des *Large Language Models*, en particulier celles des ***residual stream***[1] et ***circuit tracing***[2], au domaine de l'information géographique. L'objectif est de mettre en lumière les circuits, dans les réseaux de neurones des LLMs, qui implémentent des concepts géographiques.

Contexte

Les modèles de langues, et donc les agents conversationnels construits à partir de ceux-ci, présentent des biais géographiques[3]. En effet, la qualité des sorties de ces modèles diffère en fonction des contextes géographiques. Les générations de textes comportent, de manière globale, des informations précises et non erronées pour les pays occidentaux (Amérique du Nord et Europe de l'Ouest) et des informations générales et parfois fausses pour les autres pays dont ceux en voie de développement.
Afin de réparer cette injustice d'accès aux avancées de l'intelligence artificielle, il convient d'analyser et comprendre comment l'information géographique est encodée dans les modèles afin de corriger, de manière frugale, les différences de qualité.
L'objectif du stage est donc de sonder les modèles afin de mettre en évidence des comportements en fonction des zones géographiques incluses dans les prompts. Pour y parvenir, il faudra adapter et transférer au domaine géographique les travaux en interprétabilité mécanistique. En particulier, deux méthodes sont envisagées. La première, basée sur le *residual stream*, consiste à suivre l'évolution des représentations internes au fil des couches du modèle afin d'identifier lesquelles influencent l'information géographique[4]. La seconde, *circuit tracing*, vise à modifier une partie du modèle pour qu'il construise des attributs interprétables, pour ensuite tenter d'identifier des circuits d'activation typiques de ces attributs, à travers les couches.
Bien que de nombreux modèles de langue soient partagés en "poids ouverts", notamment par les géants du numériques, les corpus d'entraînement, les stratégies d'entraînement ou le code utilisé ne sont la plupart du temps pas partagés. C'est pourquoi, dans le cadre de ce stage, nous souhaitons travailler sur un modèle totalement ouvert : SmolLM3[5]. Ceci permettra éventuellement d'établir un lien entre les observations faîtes à propos du modèle et son entraînement, voire, éventuellement, d'agir sur son entraînement pour mesurer les répercussions sur le modèle.

Compétences du candidat/e :

- Expériences en TAL
- Programmation (Python) en TAL (Transformers, LangChain, Dspy, scikit-learn, PyTorch)
- Maîtrise de l'anglais (lu et parlé)
- Intérêt pour :
    - Explicabilité de réseaux de neurones
    - Information géographique
    - TAL

Information complémentaires :

Durée de 6 mois à partir de mars 2026.
Le stage se déroule à INRAE, dans l'UMR TETIS (Territoire, Environnement, Télédétection et Information Spatiale), située dans les locaux de la Maison de la Télédétection à Montpellier.
Le stagiaire sera encadré par Rémy Decoupes (INRAE, UMR TETIS) et Adrien Guille (Lyon 2, UR ERIC).
Pour candidater, envoyer un CV et les relevés de notes des deux derniers semestres à remy.decoupes@inrae.fr et adrien.guille@univ-lyon2.fr.

Bibliographie

1. Privileged Bases in the Transformer Residual Stream.

   https://transformer-circuits.pub/2023/privileged-basis/index.html.

2. Ameisen*, A. E. *et al.* Circuit Tracing: Revealing Computational Graphs in Language Models. *Transformer Circuits*

   https://transformer-circuits.pub/2025/attribution-graphs/methods.html.

3. Decoupes, R., Interdonato, R., Roche, M., Teisseire, M. & Valentin, S. Evaluation of geographical distortions in language models. *Mach. Learn.* **114**, 263 (2025).

4. Decoupes, R. & Guille, A. Étude des déterminants impactant la qualité de l'information géographique chez les LLMs : famille, taille, langue, quantization et fine-tuning. in *Actes de CORIA-TALN-RJCRI-RECITAL 2025. Actes de l'atelier Évaluation des modèles génératifs (LLM) et challenge 2025 (EvalLLM)* 108–119 (Association pour le Traitement Automatique des Langues, Marseille, France, 2025).

5. SmolLM3: smol, multilingual, long-context reasoner. https://huggingface.co/blog/smollm3 (2025).