Sujet de Stage : Développement d'un Système de Recherche et d'Extraction d'Information Scientifique pour la Modélisation Biomécanique

Contexte

Ce stage s'inscrit dans le cadre du projet *MoBoCk2*, un projet pluridisciplinaire associant experts en biomécanique et experts en Intelligence Artificielle ; son objectif est de modéliser numériquement la fissuration du tissu osseux.
Les défis associés aux problèmes d'accidentologie (hospitalisations liées à l'insécurité routière 21,4 Md€ en 2021), et au vieillissement de la population (50 000 fractures du col du fémur par an, coût 800 M€) sont fondamentaux. Il est crucial de gagner du temps et de la précision dans l'évaluation de l'état des victimes ou dans le diagnostic du vieillissement physiologique des tissus, comme l'ostéoporose, afin de prévenir des prises en charge médicales coûteuses et tardives, réduire les impacts économiques et peut-être redéfinir les politiques de santé publique.
À l'heure actuelle, la modélisation et la prédiction précise des mécanismes de fracture osseuse repose sur des données expérimentales. Cependant, les contraintes d'accès aux données (nombre limité d'études, restrictions éthiques, hétérogénéité des résultats) rendent nécessaire l'extraction et la structuration des connaissances existantes issues des publications scientifiques.
Un premier stage a permis de développer une pipeline d'extraction automatisée d'information scientifique, reposant sur des grands modèles de langage (LLM) en approche *few-shot*, un système de requêtage hybride (BM25 + recherche sémantique ChromaDB) et une ontologie autour de la fissuration osseuse articulant quatre concepts clés (*Essai, Spécimen, Paramètres, Fissuration*). Le système a été testé sur un corpus d'articles et avec une complétude d'extraction de 72 %.

Ce stage vise à consolider et à valoriser ces travaux.

Malgré les résultats prometteurs, plusieurs axes d'amélioration ont été identifiés :

1. Il est nécessaire d'établir un protocole d'évaluation experte pour la validation du système.
2. Une visualisation globale et interactive des données extraites doit être ajoutée à l'outil existant.
3. L'outil doit être déployé sur une infrastructure pérenne afin de permettre aux chercheurs du LBA de l'utilisation en phasde beta-tests.

Laboratoire d'accueil

La Laboratoire de Biomécanique Appliquée (LBA) est une Unité Mixte de Recherche sous la tutelle de l'Université Gustave Eiffel et d'Aix-Marseille Université, composée de 70 collaborateurs. Son site principal est localisé au cœur de la Faculté des Sciences Médicales et Paramédicales de Marseille, sur le Campus Hospitalo-Universitaire Nord. Ce laboratoire se singularise par son approche pluridisciplinaire et transversale qui réunit ingénieurs, chercheurs en biomécanique, chercheurs en intelligence artificielle et Médecins. Le LBA a ouvert récemment une antenne en région parisienne à Noisy-le-Grand sur le campus Descartes. Cette antenne est spécialisée dans les questions de recherche d'application de l'intelligence artificielle aux problématiques de santé.

Objectifs

Ce stage poursuit trois objectifs complémentaires :

1. **Déployer** le système existant sur le serveur Linux interne du LBA, afin de le rendre accessible et opérationnel pour l'ensemble des chercheurs du laboratoire.
2. **Concevoir et développer des interfaces de visualisation interactive** permettant d'explorer les résultats d'extraction à deux niveaux : une vue globale sous forme de tableau de bord expert (distribution des paramètres, couverture du corpus...) et une vue détaillée par article.
3. **Mettre en place un protocole d'évaluation** permettant aux experts en biomécanique de valider, corriger et enrichir les extractions de manière structurée, contribuant ainsi à l'amélioration continue du système.

En fonction de l'avancement, un quatrième axe pourra être exploré : l'enrichissement de l'ontologie biomécanique existante.

Étapes

1. **Déploiement et mise en production** : Conteneuriser l'application (Docker), configurer l'environnement sur le serveur Linux du LBA, mettre en place la gestion des dépendances et assurer la maintenabilité du système (documentation technique, scripts de mise à jour).
2. **Tableau de bord expert (vue globale)** : Concevoir et développer une interface de visualisation interactive permettant d'explorer l'ensemble des informations extraites du corpus : distribution des paramètres mécaniques, couverture par concept, filtres dynamiques par type d'essai, de spécimen ou de matériau.
3. **Vue par article** : Développer une interface de consultation article par article, permettant de visualiser les entités extraites et d'identifier rapidement les passages justifiant l'extraction.
4. **Protocole de validation experte** : Concevoir et intégrer un module de correction et d'annotation manuelle permettant aux experts LBA de valider ou rejeter des extractions, de proposer des corrections et de constituer un jeu de données de référence élargi.

5. **Évaluation quantitative du système** : Définir et calculer un ensemble de métriques de performance couvrant l'ensemble de la pipeline : précision, rappel et F1 sur les entités extraites, taux de complétude par concept ontologique, taux d'hallucinations, accord inter-juges sur les corrections expertes, et évolution de ces indicateurs avant/après la boucle de validation.
6. **Enrichissement de l'ontologie (optionnel)** : En collaboration avec les experts en biomécanique, réviser et étendre l'ontologie pour améliorer la couverture du domaine et intégrer d'éventuels nouveaux types d'entités identifiés lors de la validation.

Livrables

— Le système déployé et opérationnel sur le serveur interne du LBA, avec documentation de déploiement.
— Un tableau de bord interactif intégré à l'interface existante.
— Une vue de consultation par article avec traçabilité des extractions.
— Un module de validation experte (*human-in-the-loop*) fonctionnel.
— Un rapport d'évaluation documentant les métriques de qualité avant/après validation et les pistes d'amélioration de l'ontologie.

Encadrement et Collaboration

— **Encadrants principaux :**
  — Adrien Ugon *(MCF Université Gustave Eiffel — LBA, antenne ESIEE Paris)*
  — Akram Redjdal *(MCF Université Gustave Eiffel — LBA, antenne ESIEE Paris)*
— **Collaborateurs :**
  — Jean-Louis Tailhan *(Chargé de recherche, HDR — LBA)*
  — Lionel Thollon *(PU – Aix Marseille Université/ LBA)*
  — Yves *Godio-Raboutet (Ingénieur de Recherche — LBA)*

Outils et Technologies

— **Programmation :** Python (Flask, Plotly/Dash, PyMuPDF), JavaScript.
— **Déploiement :** Docker, Linux (serveur interne LBA), Nginx.
— **Systèmes de recherche :** ChromaDB, BM25 (pipeline existante).
— **Autres :** Git, Conda, outils de gestion de projets collaboratifs.

Durée et Localisation

— **Durée :** 6 mois à temps plein.
— **Localisation :** ESIEE Paris (Noisy-le-Grand, Île-de-France).