Master's Internship Project
Privacy-Preserving Detection of Long-Term Behavioral Drift in Older Adults Using a Hybrid Learning Approach

N. Bennani[1] and M. Thilliez[2]

[1] Laboratoire d'InfoRmatique en Image et Systèmes d'information, UMR 5205 CNRS, INSA Lyon, nadia.bennani@insa-lyon.fr
[2] LAMIH – UMR CNRS 8201, Université Polytechnique Hauts-de-France, INSA Hauts-de-France, marie.thilliez@uphf.fr

1 Background

The ageing population observed today raises new challenges, particularly with regard to enabling older adults to remain in their own homes, promoting their independence and allowing them to age in the best possible conditions. Smart home technologies, which rely on environmental sensors (motion detection, door opening, and object usage), make it possible to collect data on activities of daily living. These data offer significant potential for analyzing people's behavior and detecting early signs of cognitive decline, thereby helping to anticipate and prevent such problems.

Existing research in this field has focused primarily on recognizing daily activities from sensor data, making it possible to characterize older adults' lifestyle habits [9, 8], or on detecting isolated events, such as falls [6, 5]. However, these approaches do not necessarily capture gradual and persistent behavioral changes over time. Yet, such behavioral drift, identified through longitudinal analysis, may serve as an early indicator of declining independence, cognitive impairment, or the progression of neurodegenerative diseases, particularly Alzheimer's disease.

Longitudinal behavioral analysis in smart homes relies in particular on modeling daily routines in order to establish a baseline behavioral profile from observed activities. In this context, the study presented in [12] proposes a machine-learning-based approach to investigate changes in older adults' behavior over extended periods. The method relies on modeling Activities of Daily Living (ADLs) and comparing behavioral profiles using temporal similarity measures. Such approaches make it possible to investigate changes in lifestyle habits beyond the detection of isolated events, such as falls. Detecting these changes could therefore contribute to home-based monitoring and, where appropriate, enable interventions tailored to an individual's needs, with the aim of preserving their independence for as long as possible.

Techniques used to detect long-term behavioral changes require processing very large volumes of data and consequently significant computing resources to achieve good performance. Furthermore, these techniques handle sensitive data whose confidentiality must be preserved.

One possible solution is to outsource the learning process to a powerful server. While this addresses computational performance requirements, it puts data confidentiality at risk. An alternative is to process data as close as possible to the patient, for example on their personal computer. This protects data confidentiality but does not scale well given the volume of data that must be processed.

Federated learning offers a way to reconcile performance and confidentiality, as learning takes place close to the data on the patient's side while the computational workload is distributed across multiple clients. However, existing solutions are primarily designed for multi-client settings and are better suited to activity recognition or the detection of isolated anomalies.

Alharbey et al. [1, 2] propose multi-user federated learning approaches for recognizing daily activities and potentially dangerous situations over short time periods. Mondal et al. [7] propose a multi-user human activity detection solution based on federated learning that takes temporal dependencies into account. Their solution is evaluated on a relatively small dataset, making it difficult to draw firm conclusions about its performance. Finally, Shao et al. [10] propose an initial solution that analyzes a patient's overall behavior by federating the learning process locally using data collected from multiple sensors. Although this solution addresses data protection requirements, its performance remains to be established, as it has been tested on a limited volume of data.

In conclusion, existing approaches to studying behavioral drift in older adults do not simultaneously address the challenges of computational performance and data confidentiality.

Integrating Split Learning [4, 3, 11] could be a promising way to meet both performance and privacy requirements. Split learning consists of strategically distributing the layers of a neural network across multiple clients, with the aim of preventing the disclosure of sensitive data.

This internship project addresses these challenges by investigating distributed learning techniques, including federated learning and split learning, to identify approaches that meet the requirements of long-term behavioral drift detection in the context of monitoring older adults.

2 Internship Tasks

This project aims to investigate the benefits of a hybrid learning approach based on split learning for detecting long-term behavioral drift. The project will be organized around the following tasks:

- Conduct a comprehensive literature review of existing research on long-term behavioral drift detection. The objective will be to identify existing approaches to long-term behavioral modeling, the types of data used, and the datasets that could be used to validate our proposed methods.
- Conduct a comprehensive literature review of existing split learning architectures and the different possibilities for partitioning the learning process.
- Investigate the suitability of different learning architectures for long-term behavioral drift detection, considering both computational performance and patient privacy.
- Implement centralized and distributed simulations of deep learning approaches on relevant datasets to detect behavioral drift.
- Evaluate the different models and compare them with a centralized baseline. Based on the selected evaluation metrics, the proposed hybrid learning approaches will be assessed and compared with a fully centralized solution.

3 Eligibility Requirements

- Applicants must have completed, or be currently enrolled in, the second year of a Master's degree program.
- Knowledge of privacy and/or machine learning will be considered an asset.

4 Application Procedure

- Applicants must submit their application by email, including the required documents (see Section 6).
- The application deadline is November 8, 2026.
- An interview to assess the applicant's motivation may be arranged in late November.

5 Internship Details

- The internship is expected to start between February and March 2027.
- Duration: 6 months.
- The internship is paid and involves 35 working hours per week.
- The internship may be carried out either at INSA Lyon (LIRIS) or at INSA Haut-de-France (LAMIH) in Valenciennes.

6 Required Application Documents

- Curriculum vitae (CV).
- Master's Year 1 (M1) and Master's Year 2 (M2) academic transcripts (including Semester 1 results if the academic year is still in progress).
- Cover letter explaining the applicant's interest in the project and highlighting relevant skills and experience.

7 Acknowledgement

This work is part of an OpenLabs project aimed at strengthening scientific and technical cooperation between laboratories across the INSA network.

References

[1] Rania A Alharbey and Faisal Jamil. Federated learning framework for real-time activity and context monitoring using edge devices. *Sensors*, 25(4):1266, 2025.

[2] Abisek Dahal, Soumen Moulik, and Rohan Mukherjee. Fel-mar: Federated learning based multi resident activity recognition in iot enabled smart homes. *Future Generation Computer Systems*, 163:107552, 2025.

[3] Haiyu Deng, Yanna Jiang, Guangsheng Yu, Qin Wang, Xu Wang, Wei Ni, Shiping Chen, and Ren Ping Liu. Client-cooperative split learning. *IEEE Transactions on Services Computing*, 2026.

[4] Ege Erdoğan, Alptekin Küpçü, and A. Ercüment Çiçek. Unsplit: Data-oblivious model inversion, model stealing, and label inference attacks against split learning. In *Proceedings of the 21st Workshop on Privacy in the Electronic Society*, CCS '22, page 115–124. ACM, November 2022.

[5] Philippe Gorce and Julien Jacquier-Bret. Fall detection in elderly people: A systematic review of ambient assisted living and smart home-related technology performance. *Sensors*, 25(21):6540, 2025.

[6] Daniel Joseph Warrington, Elizabeth Jane Shortis, and Paula Jane Whittaker. Are wearable devices effective for preventing and detecting falls: an umbrella review (a review of systematic reviews). *BMC Public Health (Web)*, 21(1):1–12, 2021.

[7] Ananya Mondal, Mohit Kumar, and Suchetana Chakraborty. Fedmeet: Personalized federated multi-sensor fusion for privacy-preserving human activity recognition. In *Proceedings of the 27th International Conference on Distributed Computing and Networking*, pages 103–112, 2026.

[8] Qin Ni, Ana Belen Garcia Hernando, and Iván Pau De la Cruz. The elderly's independent living in smart homes: A characterization of activities and sensing infrastructure survey to facilitate services development. *Sensors*, 15(5):11312–11362, 2015.

[9] Pireh Pirzada, Neil White, and Adriana Wilde. Sensors in smart homes for independent living of the elderly. In *2018 5th International Multi-Topic ICT Conference (IMTIC)*, pages 1–8. IEEE, 2018.

[10] Xun Shao, Aoba Otani, Yuto Hirasuka, Runji Cai, and Seng W Loke. Toward dignity-aware ai: Next-generation elderly monitoring from fall detection to adl. In *International Conference on Mobile Networks and Management*, pages 453–468. Springer, 2025.

[11] Chandra Thapa, Pathum Chamikara Mahawaga Arachchige, Seyit Camtepe, and Lichao Sun. Splitfed: When federated learning meets split learning. In *Proceedings of the AAAI conference on artificial intelligence*, volume 36, pages 8485–8493, 2022.

[12] Dorsaf Zekri, Thierry Delot, Marie Thilliez, Sylvain Lecomte, and Mikael Desertot. A framework for detecting and analyzing behavior changes of elderly people over time using learning techniques. *Sensors*, 20(24):7112, 2020.

Sujet de stage de master
Détection sécurisée de dérives comportementales à long terme chez les personnes âgées via une approche hybride d'apprentissage

N. Bennani[1] and M. Thilliez[2]

[1] Laboratoire d'InfoRmatique en Image et Systèmes d'information, UMR 5205 CNRS, INSA Lyon
nadia.bennani@insa-lyon.fr
[2]LAMIH - UMR CNRS 8201, Université Polytechnique Hauts-De-France, INSA Hauts-De-France
marie.thilliez@uphf.fr

1 Contexte

Le vieillissement de la population observé aujourd'hui fait émerger de nouveaux enjeux, notamment en matière de maintien à domicile des personnes âgées, afin de favoriser leur autonomie et de leur permettre de vieillir dans les meilleures conditions possibles. Les technologies de smart home, reposant sur des capteurs environnementaux (mouvement, ouverture de portes, utilisation d'objets), permettent de collecter des données sur les activités de la vie quotidienne. Ces données offrent un potentiel important pour analyser les comportements des personnes et détecter des signes précoces de déclin cognitif afin d'anticiper et de prévenir au mieux ces problèmes.

Les travaux existants dans ce domaine portent principalement sur la reconnaissance des activités quotidiennes à partir de données issues de capteurs, permettant de caractériser les habitudes de vie des personnes âgées [9, 8], ou sur la détection d'événements ponctuels, tels que les chutes [6, 5]. Toutefois, ces approches ne permettent pas nécessairement de mettre en évidence les évolutions progressives et durables des comportements au fil du temps. Or, de telles dérives comportementales basées sur une analyse longitudinale peuvent constituer des indicateurs précoces d'une diminution de l'autonomie, d'un déclin cognitif ou de l'évolution de maladies neurodégénératives, notamment la maladie d'Alzheimer. L'analyse longitudinale des comportements dans les maisons intelligentes s'appuie notamment sur la modélisation des routines quotidiennes, afin d'établir un profil comportemental de référence à partir des activités observées. Dans cette perspective, les travaux présentés dans l'article [12] proposent une approche fondée sur l'apprentissage automatique pour étudier l'évolution des comportements des personnes âgées sur de longues périodes. La méthode repose sur la modélisation des activités de la vie quotidienne (Activities of Daily Living, ADL) et sur la comparaison des profils comportementaux à l'aide de mesures de similarité temporelle. De telles approches permettent d'étudier les changements dans les habitudes de vie au-delà de la détection d'événements ponctuels, tels que les chutes. Leur détection pourrait ainsi contribuer au suivi à domicile et permettre, lorsque cela est pertinent, de mettre en place des actions adaptées aux besoins de la personne, dans le but de préserver son autonomie aussi longtemps que possible.

Les techniques utilisées pour mettre en place la détection comportementale à long terme nécessite donc de traiter des quantités très importantes de données et par conséquent une puissance de calcul importante pour obtenir de bonnes performances. Par ailleurs, ces techniques manipulent des données sensibles dont la confidentialité doit être préservée. Ainsi, une solution qui consiste à externaliser l'apprentissage sur un serveur puissant apporte une solution au problème de performances mais met en péril la confidentialité des données. Une seconde solution qui consiste à traiter les données au plus près du patient par exemple sur son ordinateur personnel protège la confidentialité des données mais ne passe pas à l'échelle étant donné la quantité de données à traiter. L'apprentissage fédéré permet de concilier performance et confidentialité puisque l'apprentissage s'effectue au plus près des données chez le patient tout en répartissant la charge sur plusieurs clients. Cependant, les solutions existantes sont plutôt multi-clients et adaptées à la reconnaissance d'activités ou à la détection d'anomalies ponctuelles. Dans [1, 2] les auteurs proposent un apprentissage fédéré multi-utilisateurs permettant la détection d'activités quotidiennes ou dangereuses mais sur le court terme. Mondal et al. dans [7], proposent une solution multi-utilisateurs basée sur l'apprentissage fédéré de détection d'activités humaines en tenant compte de la dimension temporelle. La solution proposée est

validée sur un jeu de données de taille réduite et ne permet pas de conclure sur les performances obtenues. Enfin, Shao et al. dans [10] proposent une première solution qui analyse le comportement global d'un patient en fédérant localement l'apprentissage sur des données en provenance de plusieurs capteurs. Cette solution répond aux exigences de protection des données mais pas à celui des performances puisqu'elle a été testée sur un volume réduit de données. En conclusion, les solutions connues d'étude sur les glissements de comportement des personnes âgées n'adressent pas simultanément les problématiques de performance et de confidentialité des données.

Intégrer le partitionnement de l'apprentissage (Split Learning) [4, 3, 11] pourrait être une solution intéressante pour répondre aux exigences en termes de performances et de confidentialité. Le Split Leaning consiste à répartir judicieusement les couches du réseau de neurones sur plusieurs clients en ayant pour objectif de ne pas divulguer de données sensibles. C'est dans ce contexte que s'inscrit ce sujet de stage, dont l'objectif est d'étudier les techniques de partitionnement de l'apprentissage (apprentissage fédéré, apprentissage par partitionnement) qui répondraient aux besoins de la détection de dérives comportementales à long terme dans le suivi des personnes âgées.

2 Etapes du stage

Dans ce sujet, nous souhaitons étudier l'apport d'une approche hybride d'apprentissage basée sur le split learning pour la détection de dérives comportementales à long terme. Les étapes du projet sont définies comme suit :

- Etablissement d'un état de l'art exhaustif des travaux portant sur la détection des dérives comportementales à long terme. L'objectif sera d'identifier les modélisations de comportement à long terme existantes ainsi que les types de données utilisées et enfin les jeux de données qui pourraient valider nos propositions.
- Etablissement d'un état de l'art exhaustif sur les architectures de split learning existantes et les possibilités de partitionnement de l'apprentissage.
- Etude de l'adéquation des architectures d'apprentissage aux besoins de la détection des dérives à long terme en termes de performance mais également en prenant en compte la vie privée des patients.
- Simulation centralisée et répartie d'un apprentissage de type deep learning sur les jeux de données pour détecter les dérives de comportement.
- Evaluation des différents modèles et comparaison avec le modèle centralisé : en fonction des métriques définis, nous pourrons évaluer les différents modèles d'hybridation proposés et les comparer avec une solution complètement centralisée.

3 Eligibilité

- Le candidat doit avoir suivi ou est inscrit en seconde année d'un cursus de master.
- Des connaissances en privacy et/ou en machine learning seront appréciées.

4 Candidature

- Le candidat doit adresser par mail une candidature en joignant les documents requis (cf section 6).
- La date limite pour candidater est le 8 Novembre 2026.
- Un entretien de motivation pourra être organisé fin Novembre.

5 Informations sur le stage

- Le stage devra commencer en Fevrier-Mars 2027
- La durée du stage est de 6 mois
- Le stage est rémunéré pour un volume horaire de 35 heures/semaine

- Le stage pourra être localisé au choix à l'INSA Lyon au LIRIS ou à INSA Haut-de-France au LAMIH à Valenciennes

6 Documents requis

- CV du candidat
- Relevés de notes du M1 et du M2 (semestre 1 si en cours)
- Lettre de motivation expliquant l'intérêt pour le sujet et les compétences en rapport avec le sujet

7 Mention

Ce travail s'inscrit dans le cadre d'un projet OpenLabs visant à renforcer la coopération scientifique et technique entre les laboratoires des différents INSA.

References

[1] Rania A Alharbey and Faisal Jamil. Federated learning framework for real-time activity and context monitoring using edge devices. *Sensors*, 25(4):1266, 2025.

[2] Abisek Dahal, Soumen Moulik, and Rohan Mukherjee. Fel-mar: Federated learning based multi resident activity recognition in iot enabled smart homes. *Future Generation Computer Systems*, 163:107552, 2025.

[3] Haiyu Deng, Yanna Jiang, Guangsheng Yu, Qin Wang, Xu Wang, Wei Ni, Shiping Chen, and Ren Ping Liu. Client-cooperative split learning. *IEEE Transactions on Services Computing*, 2026.

[4] Ege Erdoğan, Alptekin Küpçü, and A. Ercüment Çiçek. Unsplit: Data-oblivious model inversion, model stealing, and label inference attacks against split learning. In *Proceedings of the 21st Workshop on Privacy in the Electronic Society*, CCS '22, page 115–124. ACM, November 2022.

[5] Philippe Gorce and Julien Jacquier-Bret. Fall detection in elderly people: A systematic review of ambient assisted living and smart home-related technology performance. *Sensors*, 25(21):6540, 2025.

[6] Daniel Joseph Warrington, Elizabeth Jane Shortis, and Paula Jane Whittaker. Are wearable devices effective for preventing and detecting falls: an umbrella review (a review of systematic reviews). *BMC Public Health (Web)*, 21(1):1–12, 2021.

[7] Ananya Mondal, Mohit Kumar, and Suchetana Chakraborty. Fedmeet: Personalized federated multi-sensor fusion for privacy-preserving human activity recognition. In *Proceedings of the 27th International Conference on Distributed Computing and Networking*, pages 103–112, 2026.

[8] Qin Ni, Ana Belen Garcia Hernando, and Iván Pau De la Cruz. The elderly's independent living in smart homes: A characterization of activities and sensing infrastructure survey to facilitate services development. *Sensors*, 15(5):11312–11362, 2015.

[9] Pireh Pirzada, Neil White, and Adriana Wilde. Sensors in smart homes for independent living of the elderly. In *2018 5th International Multi-Topic ICT Conference (IMTIC)*, pages 1–8. IEEE, 2018.

[10] Xun Shao, Aoba Otani, Yuto Hirasuka, Runji Cai, and Seng W Loke. Toward dignity-aware ai: Next-generation elderly monitoring from fall detection to adl. In *International Conference on Mobile Networks and Management*, pages 453–468. Springer, 2025.

[11] Chandra Thapa, Pathum Chamikara Mahawaga Arachchige, Seyit Camtepe, and Lichao Sun. Splitfed: When federated learning meets split learning. In *Proceedings of the AAAI conference on artificial intelligence*, volume 36, pages 8485–8493, 2022.

[12] Dorsaf Zekri, Thierry Delot, Marie Thilliez, Sylvain Lecomte, and Mikael Desertot. A framework for detecting and analyzing behavior changes of elderly people over time using learning techniques. *Sensors*, 20(24):7112, 2020.